



Stratégie d'investissement basée sur l'analyse de sentiments

Réalisé par:

Skander Kammoun

encadré par:

Mme Amel Hedhli

Plan

1. Introduction

2. Cadre général du projet

3. Collecte des données

4. Prétraitement des données

5. Analyse de sentiment (NLP)

6. Analyse exploratoire des données (EDA)



Introduction et Problématique



Les limites de la finance classique

Le marché boursier est un système complexe et volatil où les mathématiques traditionnelles peinent à anticiper les mouvements dictés par les émotions humaines.

Objectif principal

Minimiser les prédictions inexactes qui génèrent des pertes financières



Problématique centrale

Minimiser les prédictions inexactes qui génèrent des pertes financières

Fondement scientifique

Stratégie basée sur l'état de l'art mondial et la revue de littérature de 4 études scientifiques majeures (2017-2026)

Cadre général du projet



Approche Multi-Sources

Exploitation simultanée de données textuelles (Réseaux sociaux, Presse) et de données financières (Prix historiques)

Extraction de Sentiment (NLP)

Rejet des approches lexicales classiques au profit du Deep Learning et des modèles Transformer

Stratégies Hybrides

Combinaison de l'analyse de sentiment avec des indicateurs financiers traditionnels et des réseaux de neurones à mémoire (LSTM)

Évaluation et Métriques strictes

Rejet de la Précision au profit du F-Score et du MCC pour empêcher l'algorithme de tricher face aux déséquilibres du marché

Collecte des données

- **Identification des actions**

- Google : GOOGL
- Apple : AAPL
- Facebook (Meta) : META
- Amazon : AMZN
- Microsoft : MSFT
- Tesla : TSLA
- UnitedHealth Group (UNH) : Le plus grand assureur santé au monde (parfait pour l'actuariat).
- Berkshire Hathaway (BRK-B) : L'empire de Warren Buffet, qui possède le géant de l'assurance GEICO.
- JPMorgan Chase (JPM) : La plus grande banque américaine



- **Le Manque de data** : Le volume quotidien de publications sur les actions africaines est statistiquement insuffisant pour alimenter l'IA de manière continue.
- **L'IA est parfait avec l'anglais** : Les modèles NLP actuels, comme FinBERT, sont spécialisés dans l'anglais financier et ne maîtrisent pas les langues utilisées sur les marchés africains (français, arabe, dialectes).
- **La réaction du marché** : Les marchés africains étant moins liquides et moins réactifs, le décalage temporel entre la sortie d'une actualité et son impact réel sur les prix fausse les calculs de l'algorithme.

Collecte des données

- **les données financiers**



Yahoo Finance



Tingo

- **Les données textuelles**
 - **Les Reseaux sociaux**

StockTwits

Reddit WallStreetBets

Reddit Stocks

La collecte des données est réalisée à travers deux méthodes :

- Scrapping en utilisant la biblio selenium Base
- la collecte avec Kaggle

- **Les données textuelles**
 - **Les articles scientifiques**

YFinance

flux ress de google



finhub api





Prétraitement des données

- **Les données textuelles**

- Dans cette étape, j'explore chaque source de données afin d'en vérifier la qualité et la structure. Cette analyse comprend notamment la vérification de la structure des données, l'identification des valeurs manquantes, la détection des doublons ainsi que l'analyse des valeurs uniques de chaque variable.
- Pour les données publiées après la clôture de la séance boursière, j'applique une projection temporelle en décalant leur date de publication d'un jour (+1 jour). Cette opération permet d'associer chaque information à la première séance de marché durant laquelle elle est effectivement disponible pour les investisseurs.
- Enfin, je procède à la fusion de l'ensemble des sources de données dans un jeu de données unique. Le fichier obtenu, MASTER_DATASET_BRUT_MAX.csv, contient les principales colonnes suivantes : Source, Ticker, Date de publication et Titre.

L'EDA réalisée sur le dataset initial (3,8 millions de lignes) a révélé deux problèmes majeurs :

- **Déséquilibre de classes** : TSLA représentait à lui seul plus de 2,1 millions de messages, dominant largement le reste du dataset.
- **Hétérogénéité des données** : Les données étaient divisées en deux groupes distincts :
 - Top 4 (TSLA, AAPL, AMZN, META) : messages issus des réseaux sociaux (2020–2022), au langage informel.
 - Autres tickers : actualités financières (2025–2026), au style plus formel.
- **Décision** : Conserver uniquement le Top 4 afin d'obtenir un jeu de données plus cohérent et adapté à l'entraînement du modèle.



• Traitement pour Finbert

- Supprimer les URLs (https://...).
- Supprimer les identifications d'utilisateurs (@elonmusk).
- Nettoyer les balises HTML résiduelles (transformer & en &).



- FinBERT est un modèle basé sur l'architecture Transformer. Contrairement aux anciens modèles, il ne lit pas les mots un par un (Bag of Words), mais il lit la phrase entière pour comprendre le contexte bidirectionnel.
- Le danger des Stop Words : NLTK considère des mots comme 'not', 'down', 'up', 'over', 'under' comme des mots vides (stopwords). Si on les supprime, la phrase "TSLA earnings are not good, stock goes down" devient "TSLA earnings good, stock goes".
- La Ponctuation est cruciale : FinBERT utilise la ponctuation pour comprendre l'intensité et la structure. Un point d'exclamation ("Buy now!") ou un point d'interrogation ("Buy now?") change tout le sens.
- La Lemmatisation est inutile : FinBERT possède son propre "Tokenizer" (WordPiece) qui gère intelligemment les racines et les terminaisons.

Prétraitement des données

- **Les données financiers**

- Filtrage du dataset : conservation des données des Top 4 tickers (TSLA, AAPL, AMZN, META) sur la période 2020-2022.
- **Contrôle de la qualité des données** : détection des valeurs manquantes, des doublons et des valeurs aberrantes (outliers).
- **Ajout de la variable StockChange**: Pour mesurer la variation du prix d'une action, nous utilisons le rendement intra-journalier :

$$StockChange = \frac{Close - Open}{Open}$$

Pourquoi ?

- Élimine l'effet des variations hors heures de marché (overnight gap).
- Isole uniquement la réaction des investisseurs pendant les heures d'ouverture.
- Réduit le bruit et fournit une mesure plus pertinente pour l'entraînement du modèle.

Analyse de sentiment (NLP)

- **benchmarking entre les tokenizers**
 - ProsusAI/finbert
 - yiyanghkust/finbert-tone
 - ahmedrachid/FinancialBERT-Sentiment-Analysis

Critère	ProsusAI/finbert	yiyanghkust/finbert-tone
Type de données d'entraînement	Articles de presse financière	Documents financiers corporate (rapports, communications officielles)
Comportement	Probabilités nuancées (ex. 61% négatif, 29% neutre, 9% positif)	Prédictions très tranchées (souvent proches de 0% ou 100%)
Interprétation des termes	Peut être influencé par certains mots-clés et le contexte médiatique	Analyse davantage le ton financier et le contexte corporate
Exemple : "skyrocketing stock price"	Peut classer en négatif car le terme peut être associé à des risques ou une spéculation	Peut classer en neutre car absence d'indicateurs financiers explicites
Gestion du sensationnalisme	Plus sensible aux formulations émotionnelles	Plus robuste face au langage promotionnel
Détection des crises	Bonne détection mais avec une approche probabiliste	Très sensible aux signaux négatifs forts (ex. <i>bankruptcy</i> → négatif)
Cas d'utilisation recommandé	Analyse du sentiment dans les articles et actualités financières	Analyse du sentiment dans les rapports et communications d'entreprise

- **Décision** : Puisque FinancialBERT ne reconnaît pas suffisamment le contexte spécifique de Tesla, nous avons choisi FinBERT-tone, mieux adapté à notre analyse.



Indicateur de sentiment



Le Score de Sentiment Net

Il indique simplement qui gagne la bataille globale entre l'optimisme et le pessimisme sur une journée donnée.

$$Score_{Net} = \mu_{Positive} - \mu_{Negative}$$



L'Indice d'Optimisme

Il mesure la proportion d'acheteurs uniquement parmi les personnes qui ont un avis tranché, en ignorant totalement les indécis (le bruit neutre).

$$Bullishness = \frac{\mu_{Positive}}{\mu_{Positive} + \mu_{Negative}}$$





L'Indice de Polarité

Il évalue l'intensité du désaccord et de la tension sur le marché pour t'aider à anticiper les journées explosives à forte volatilité.

$$Polarite = 1 - \mu_{Neutre}$$



Analyse exploratoire des données (EDA)



L'impact variable : Le sentiment d'internet n'influence pas toutes les actions de la même manière.




Les actions émotives : Les valeurs technologiques très populaires (comme Tesla ou Meta) réagissent immédiatement et violemment au bruit médiat



Le pouvoir d'anticipation : Sur certaines actions (comme UNH ou MSFT), l'humeur des textes permet à l'IA d'anticiper une baisse des prix bien avant qu'elle ne se produise.



Les limites de l'IA : Les actions institutionnelles traditionnelles (comme Berkshire Hathaway) ignorent totalement l'humeur d'internet,





**Merci de votre
attention.**