

Revue de Littérature : Stratégies d'investissement basées sur l'analyse de sentiment et les données textuelles

Projet de Fin d'Études - Actuariat
Skander

17 juin 2026

Table des matières

1	Introduction et Problématique	2
2	Les Sources de Données : Finance et Texte	2
2.1	Données Textuelles	2
2.2	Données Financières et Variable Cible	2
3	Outils d'Extraction du Sentiment	2
3.1	L'Approche Lexicale : TextBlob et VADER	3
3.2	L'Approche Deep Learning et Transformers	3
4	Modélisation Prédictive et Stratégies Hybrides	3
5	Évaluation et Métriques : La nécessité du F-Score	3
6	Tableau Synthétique des Études	4
7	Conclusion	4

1 Introduction et Problématique

Le marché boursier est un système complexe et hautement volatil où les mathématiques traditionnelles peinent à anticiper les mouvements dictés par les émotions humaines. L'objectif principal de ce projet n'est pas seulement d'obtenir les meilleurs rendements, mais de minimiser les prédictions inexactes qui génèrent des pertes financières. La problématique centrale est la suivante : *Comment fusionner efficacement des flux de données asynchrones (données financières et données textuelles) tout en minimisant le bruit, et comment combiner l'analyse de sentiment avec des indicateurs financiers traditionnels pour créer un système de prédiction robuste ?*

Cette revue de littérature s'appuie sur quatre études scientifiques majeures publiées entre 2017 et 2026 pour établir l'état de l'art mondial sur ce sujet.

2 Les Sources de Données : Finance et Texte

La littérature démontre que le choix des sources de données est crucial pour la réussite des modèles. Les chercheurs divisent généralement leurs ensembles de données en deux blocs :

2.1 Données Textuelles

- **Les flux RSS et la Presse Économique :** L'étude de Bharathi & Geetha (2017) utilise les flux RSS (fichiers XML) de sites spécialisés pour obtenir des données sans "bruit" ni spam. Jishtu et al. (2022) utilisent le *Web Scraping* pour aspirer des articles d'Investing.com. Selon la revue systématique de Zhao & Tang (2026), les actualités financières sont les sources les plus utilisées (67.8% des études).
- **Les Réseaux Sociaux :** Koukaras et al. (2022) exploitent Twitter et StockTwits pour capter l'humeur instantanée des investisseurs (utilisés dans 58.6% des études).

2.2 Données Financières et Variable Cible

Les prix historiques sont récupérés via des API comme Yahoo Finance. Pour isoler les mouvements du marché sans subir le bruit des "gaps" d'ouverture (sauts de prix durant la nuit), Koukaras et al. (2022) recommandent la formule mathématique suivante pour définir la variation intra-day :

$$StockChange = \frac{Close - Open}{Open}$$

3 Outils d'Extraction du Sentiment

L'extraction de l'information textuelle nécessite un nettoyage (suppression des *stop words*) et une normalisation via des techniques comme le *Stemming* (couper la racine du mot) ou la *Lemmatisation* (Jishtu et al., 2022). Le texte est ensuite transformé en vecteurs (TF-IDF, Word2Vec) ou analysé via différentes générations d'outils :

3.1 L'Approche Lexicale : TextBlob et VADER

Ces outils classiques n'utilisent pas d'Intelligence Artificielle. Ils fonctionnent comme un correcteur utilisant un dictionnaire géant où chaque mot possède une note (ex : "bénéfice" vaut +2, "faillite" vaut -3).

- **TextBlob** : Classe simplement chaque texte en positif, négatif ou neutre.
- **VADER** : Plus adapté aux réseaux sociaux, il évalue l'intensité de l'émotion (4 notes : positive, négative, neutre, globale). Il repère les majuscules, la ponctuation et les inversions de sens.

Limites de ces approches : Comme le soulignent Koukaras et al. (2022), VADER échoue face au sarcasme et ne comprend pas la finance. Par exemple, pour l'expression "*le chômage s'effondre*", VADER détecte le mot "s'effondre" (négatif) et attribue une mauvaise note, alors qu'en finance, il s'agit d'un signal positif.

3.2 L'Approche Deep Learning et Transformers

Pour surmonter les limites lexicales, l'état de l'art se tourne vers les Grands Modèles de Langage (LLMs). Zhao & Tang (2026) confirment que l'architecture Transformer, notamment **FinBERT** (entraîné sur du vocabulaire financier), domine aujourd'hui la recherche.

4 Modélisation Prédictive et Stratégies Hybrides

Les études démontrent l'importance de comparer plusieurs algorithmes de prédiction :

- **L'Approche Hybride (Indicateurs + Sentiment)** : Bharathi & Geetha (2017) combinent le NLP avec un indicateur technique classique : la Moyenne Mobile (*Moving Average*). Si la moyenne courte dépasse la moyenne longue, le signal est positif :

$$F_t = \frac{A_{t-1} + A_{t-2} + \dots + A_{t-n}}{n}$$

- **Séries Temporelles avec Mémoire** : Jishtu et al. (2022) démontrent que les modèles statistiques classiques (ARIMA/SARIMA) sont incapables de comprendre la bourse sur la durée. Le modèle de réseau de neurones **LSTM** (Long Short-Term Memory) écrase la concurrence avec une précision de 78.81%.

5 Évaluation et Métriques : La nécessité du F-Score

Koukaras et al. (2022) mettent en garde contre l'utilisation de la précision globale (*Accuracy*). Les marchés financiers sont déséquilibrés : la bourse a historiquement plus tendance à monter qu'à baisser. Un algorithme "stupide" qui conseillerait toujours d'acheter obtiendrait une bonne précision artificielle.

Pour empêcher l'algorithme de tricher, la recherche impose l'utilisation du **F-Score** et de l'AUC-ROC. Zhao & Tang (2026) préconisent également le *Matthews Correlation Coefficient* (MCC) pour les jeux de données déséquilibrés :

$$MCC = \frac{TP \times TN - FP \times FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}}$$

6 Tableau Synthétique des Études

Auteurs (Année)	Données	Modèles NLP	Prédictions	Limites Identifiées
Bharathi & Geetha (2017)	RSS News + ASE (Arab Bank)	POS Tagger + Dictionnaire (WordNet)	Moyenne Mobile hybride Accuracy : 78.75%	Dictionnaire basique et données anciennes (2006).
Koukaras et al. (2022)	Twitter + Yahoo Finance	VADER vs TextBlob	SVM, KNN, RF F-Score : 76.3%	VADER et TextBlob n'ont pas d'IA. Ils échouent sur le sarcasme et la terminologie financière.
Jishtu et al. (2022)	Scraping News + FTSE 100	Stemming, TF-IDF, Word2Vec	LSTM vs ARIMA Accuracy : 78.81%	Les modèles statistiques classiques (ARIMA) sont inadaptés sur le long terme.
Zhao & Tang (2026)	Revue Systématique (87 études)	Lexiques classiques jusqu'aux LLMs	Transformers (FinBERT) Accuracy : 65.28%	Bruit (bots), biais américain, et décomposition temporelle de l'information (5-8 jours).

TABLE 1 – Comparaison des approches d'analyse de sentiment pour la prédiction boursière.

7 Conclusion

Cette revue de littérature valide pleinement la faisabilité de notre PFE. Pour proposer une stratégie d'investissement robuste, il sera indispensable d'éviter les lexiques simples au profit de modèles d'IA contextuels (FinBERT), d'utiliser des algorithmes avec mémoire temporelle (LSTM) couplés à des indicateurs techniques, et d'évaluer la performance avec des métriques strictes (F-Score) pour pallier les biais naturels des marchés financiers.