

Revue de Littérature : Stratégies d'investissement basées sur l'analyse de sentiment et les données textuelles

Projet de Fin d'Études - Actuariat
Skander

17 juin 2026

Table des matières

1	Introduction	2
2	Sources de Données : Finance et Texte	2
3	Évolution des Modèles : Du Lexique aux Transformers	2
4	Méthodologies d'Évaluation	3
5	Tableau Synthétique et Comparatif	3
6	Défis et Pistes pour le Projet	3
7	Conclusion	3

1 Introduction

Le marché boursier est un système complexe hautement volatil où les mathématiques traditionnelles peinent à intégrer l'impact des émotions humaines et des événements macroéconomiques. La littérature scientifique récente démontre que l'analyse des données textuelles (actualités, réseaux sociaux) permet de capter des signaux prédictifs que les prix seuls ne reflètent pas (Zhao & Tang, 2026). Cet état de l'art synthétise quatre études majeures afin d'évaluer dans quelle mesure l'analyse de sentiment peut améliorer la performance et la robustesse des stratégies d'investissement.

2 Sources de Données : Finance et Texte

L'efficacité d'un modèle prédictif repose sur la qualité de ses données. La littérature met en évidence une dichotomie dans les sources textuelles exploitées :

- **Les réseaux sociaux (Twitter, StockTwits) :** Utilisés par Koukaras et al. (2022), ils offrent une grande réactivité mais souffrent d'un niveau de bruit élevé (sarcasme, bots).
- **Les actualités financières (RSS, Investing.com) :** Privilégiées par Bharathi & Geetha (2017) et Jishtu et al. (2022), ces sources sont plus fiables et structurées. Zhao & Tang (2026) soulignent d'ailleurs que les actualités financières sont utilisées dans 67.8% des études académiques performantes.

Pour la variable cible boursière, les auteurs s'accordent sur l'utilisation des prix historiques (Yahoo Finance, Amman Stock Exchange). L'isolation du mouvement *intra-day* est souvent privilégiée via la formule suivante :

$$\text{StockChange} = \frac{\text{Close} - \text{Open}}{\text{Open}} \quad (1)$$

3 Évolution des Modèles : Du Lexique aux Transformers

L'extraction du sentiment a connu une évolution technologique majeure :

1. **Approches Lexicales :** Les outils comme VADER ou les dictionnaires spécifiques à la finance (WordNet, Loughran-McDonald) attribuent des scores aux mots. Bien que basiques et limités face à la terminologie financière (Koukaras et al., 2022), ils constituent une ligne de base (baseline) efficace.
2. **Machine Learning (ML) et Deep Learning (DL) :** L'utilisation de modèles SVM associés à VADER a permis d'atteindre un F-Score de 76.3% sur Twitter. Plus récemment, les réseaux de neurones récurrents comme les LSTM (Long Short-Term Memory) ont prouvé leur supériorité sur les modèles statistiques classiques (ARIMA/SARIMA) avec une précision atteignant 78.81% (Jishtu et al., 2022).
3. **Grands Modèles de Langage (LLMs) :** La revue systématique de Zhao & Tang (2026) confirme que les architectures de type Transformer (FinBERT) dominent désormais l'état de l'art, capables de comprendre le contexte financier complexe avec une précision directionnelle atteignant 65.28% sur des indices majeurs comme le S&P 500.

4 Méthodologies d'Évaluation

En raison du déséquilibre structurel des marchés financiers (tendance haussière naturelle), l'utilisation de la simple précision (*Accuracy*) est trompeuse. Les chercheurs imposent l'usage du F-Score, de l'AUC-ROC, et du *Matthews Correlation Coefficient* (MCC) :

$$MCC = \frac{TP \times TN - FP \times FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}} \quad (2)$$

5 Tableau Synthétique et Comparatif

!			
Auteurs (Année)	Données	Modèles NLP	Modèles Prédictifs
Bharathi & Geetha (2017)	RSS News + ASE	Dictionnaire (WordNet)	Moyenne Mobile (HY)
Koukaras et al. (2022)	Twitter + Yahoo Fin.	VADER vs TextBlob	SVM, KNN, RF
Jishtu et al. (2022)	News + FTSE 100	TF-IDF, Word2Vec	LSTM vs ARIMA/SARIMA
Zhao & Tang (2026)	Revue Systématique (87)	Lexiques à LLMs	Transformers (FinBERT)

TABLE 1 – Comparaison des études sur la prédiction boursière par analyse de sentiment.

6 Défis et Pistes pour le Projet

La littérature met en lumière plusieurs défis critiques que ce projet devra adresser :

- **Le Bruit et l'Influence** : Sur les réseaux sociaux, le sarcasme et les robots faussent les résultats. Il est nécessaire d'appliquer des filtres de pondération basés sur l'influence des auteurs.
- **La Décomposition Temporelle (*Temporal Decay*)** : Zhao & Tang (2026) rappellent que le signal textuel perd son utilité très rapidement (5 à 8 jours). Le modèle prédictif devra donc être réactif.
- **L'Approche Hybride** : Comme démontré par Bharathi & Geetha (2017), la combinaison d'indicateurs techniques (ex : Moyennes Mobiles) :

$$F_t = \frac{A_{t-1} + A_{t-2} + \dots + A_{t-n}}{n} \quad (3)$$

avec l'analyse de sentiment (FinBERT) offre les performances les plus robustes.

7 Conclusion

Cette revue de littérature confirme la validité et l'ambition de notre problématique. Pour surpasser les approches existantes, notre méthodologie s'appuiera sur l'architecture Transformer (FinBERT) appliquée à des données de presse fiables, couplée à des modèles de Deep Learning (LSTM) et des indicateurs techniques, tout en intégrant une dimension de gestion des risques inhérente à l'actuariat.